การถดถอยเชิงเส้น

Module 03 — Linear Regression

BDAT501 Data Science Fundamentals

คณะวิศวกรรมศาสตร์ · มหาวิทยาลัยมหิดล

ผู้สอน: **ผศ.ดร. ทวีศักดิ์ สมานชื่น**

วัตถุประสงค์การเรียนรู้

เมื่อจบ module นี้ นักศึกษาสามารถ:

1. **อธิบาย** หลักการของ Linear Regression และ Ordinary Least Squares (OLS)
2. **อธิบาย** สมมติฐาน (assumptions) ที่จำเป็นสำหรับ Linear Regression
3. **ประยุกต์ใช้** Simple และ Multiple Linear Regression กับข้อมูลจริง
4. **ประยุกต์ใช้** scikit-learn เพื่อสร้างและประเมินโมเดล
5. **วิเคราะห์** ผลลัพธ์โมเดลด้วย R^2, MAE, RMSE และ Residual Plot

เนื้อหาใน Module นี้

1. **แนวคิดและแรงจูงใจ** — ทำไมต้องใช้ Regression?
2. **Simple Linear Regression** — สมการ, การประมาณค่า OLS
3. **Multiple Linear Regression** — ตัวแปรอิสระหลายตัว, Multicollinearity
4. **Worked Example** — ทำนายราคาบ้านด้วย Boston Housing Dataset
5. **การประเมินผลโมเดล** — R^2, MAE, RMSE, Residual Analysis

01

แนวคิดและแรงจูงใจ

Why Regression? What Problem Does It Solve?

Regression คืออะไร?

นิยาม

Regression คือกลุ่มของวิธีการทางสถิติที่ใช้อธิบาย**ความสัมพันธ์**
ระหว่างตัวแปรตาม y กับตัวแปรอิสระ x หนึ่งตัวหรือมากกว่า

ตัวอย่างปัญหาจริงที่ใช้ Regression

- **ราคาบ้าน** จากพื้นที่ใช้สอย, ทำเล, จำนวนห้อง
- **ยอดขาย** จากงบโฆษณา, ฤดูกาล
- **ความเสี่ยงโรค** จากอายุ, BMI, ระดับน้ำตาลในเลือด

ความแตกต่างจาก Classification: Regression ทำนายค่า**ต่อเนื่อง** ไม่ใช่ป้ายกำกับ (label)

Supervised Learning Framework

โครงสร้างของปัญหา Regression

Input (Features) X

- ตัวแปรอิสระ $x_1, x_2, \ldots, x_p$
- เรียกว่า predictors หรือ covariates
- ชนิด: ตัวเลข, Categorical (ต้องแปลง)

Output (Target) y

- ตัวแปรตาม (continuous)
- คือสิ่งที่เราต้องการทำนาย
- ตัวอย่าง: ราคา, อุณหภูมิ, คะแนน

เป้าหมาย: หาฟังก์ชัน $\hat{f}$ ที่ดีที่สุด เพื่อให้ $\hat{y} = \hat{f}(X)$ ใกล้เคียง y มากที่สุด

02

Simple Linear Regression

One Feature, One Target

สมการ Simple Linear Regression

รูปแบบสมการ

$$y = \beta_0 + \beta_1 x + \varepsilon$$

- y — ตัวแปรตาม (target)
- x — ตัวแปรอิสระ (feature)
- β_0 — จุดตัดแกน y (intercept)
- β_1 — ความชัน (slope): การเปลี่ยนแปลงของ y เมื่อ x เพิ่ม 1 หน่วย
- ε — ความคลาดเคลื่อน (error term), สมมติว่า $\varepsilon \sim \mathcal{N}(0, \sigma^2)$

Ordinary Least Squares (OLS)

เป้าหมาย: หา $\hat{\beta}_0, \hat{\beta}_1$ ที่ minimize

$$\text{RSS} = \sum_{i=1}^{n}(y_i - \hat{y}_i)^2 = \sum_{i=1}^{n}(y_i - \hat{\beta}_0 - \hat{\beta}_1 x_i)^2$$

Closed-form Solution

$$\hat{\beta}_1 = \frac{\sum_{i=1}^{n}(x_i - \bar{x})(y_i - \bar{y})}{\sum_{i=1}^{n}(x_i - \bar{x})^2} \qquad \hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x}$$

Residual $e_i = y_i - \hat{y}_i$ คือระยะห่างแนวตั้งระหว่างจุดข้อมูลกับเส้นถดถอย

Assumptions ของ Linear Regression

สมมติฐาน LINE

ตัวอักษร	สมมติฐาน	วิธีตรวจสอบ
Linearity	ความสัมพันธ์เป็นเส้นตรง	Scatter plot, Residual vs Fitted
Independence	ข้อมูลแต่ละตัวอิสระต่อกัน	Durbin-Watson test
Normality	Error มีการแจกแจงปกติ	Q-Q plot, Shapiro-Wilk
Equal variance	Homoscedasticity	Scale-Location plot

03

Multiple Linear Regression

More Features, Better Predictions?

สมการ Multiple Linear Regression

รูปแบบ Matrix

$$\mathbf{y} = \mathbf{X}\boldsymbol{\beta} + \boldsymbol{\varepsilon}$$

รูปแบบทั่วไป

$$y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \cdots + \beta_p x_p + \varepsilon$$

OLS Solution แบบ Matrix

$$\hat{\boldsymbol{\beta}} = (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{y}$$

Multicollinearity

ปัญหาเมื่อตัวแปรอิสระสัมพันธ์กันสูง

- ค่า coefficient ไม่เสถียร — เปลี่ยนมากเมื่อเพิ่ม/ลบตัวแปร
- Standard error ของ coefficient สูงผิดปกติ
- ตีความ β_j ได้ยาก

ตรวจสอบด้วย Variance Inflation Factor (VIF)

$$\text{VIF}_j = \frac{1}{1 - R_j^2}$$

- **VIF < 5** — ยอมรับได้
- **VIF ≥ 10** — มีปัญหา Multicollinearity รุนแรง

04

Worked Example

ทำนายราคาบ้านด้วย California Housing Dataset

Dataset: California Housing

ข้อมูล

- **Source:** `sklearn.datasets.fetch_california_housing()`
- **จำนวน:** 20,640 ตัวอย่าง · 8 features
- **Target:** ราคาบ้านเฉลี่ย (median house value, หน่วย $100,000)

Feature	คำอธิบาย
`MedInc`	รายได้เฉลี่ยของครัวเรือน
`HouseAge`	อายุบ้านเฉลี่ย
`AveRooms`	จำนวนห้องเฉลี่ยต่อครัวเรือน
`Latitude`, `Longitude`	พิกัดภูมิศาสตร์

โค้ดตัวอย่าง: Load & Explore

```
from sklearn.datasets import fetch_california_housing
import pandas as pd
import matplotlib.pyplot as plt

# โหลดข้อมูล
housing = fetch_california_housing(as_frame=True)
df = housing.frame

print(df.shape)       # (20640, 9)
print(df.describe())  # สถิติเบื้องต้น
```

โค้ดตัวอย่าง: Load & Explore (ต่อ)

```
# ดูความสัมพันธ์กับ target
df.corr()["MedHouseVal"].sort_values(ascending=False)
```

ผลลัพธ์: `MedInc` มีความสัมพันธ์สูงที่สุดกับราคาบ้าน ($r \approx 0.69$)

โค้ดตัวอย่าง: Train & Evaluate

```
from sklearn.linear_model import LinearRegression
from sklearn.model_selection import train_test_split
from sklearn.metrics import mean_absolute_error, root_mean_squared_error, r2_score
from sklearn.preprocessing import StandardScaler

X, y = df.drop("MedHouseVal", axis=1), df["MedHouseVal"]
X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.2, random_state=42)

scaler = StandardScaler()
X_train_s = scaler.fit_transform(X_train)
X_test_s  = scaler.transform(X_test)
```

โค้ดตัวอย่าง: Train & Evaluate

```
model = LinearRegression().fit(X_train_s, y_train)
y_pred = model.predict(X_test_s)

print(f"R²   = {r2_score(y_test, y_pred):.3f}")
print(f"MAE  = {mean_absolute_error(y_test, y_pred):.3f}")
print(f"RMSE = {root_mean_squared_error(y_test, y_pred):.3f}")
```

05

การประเมินผลโมเดล

Evaluation Metrics & Residual Analysis

Regression Metrics

Metric	สูตร	ความหมาย	ช่วงค่า
MAE	$\frac{1}{n}\sum	y_i - \hat{y}_i	$
RMSE	$\sqrt{\frac{1}{n}\sum(y_i - \hat{y}_i)^2}$	ลงโทษ outlier มากกว่า	$[0, \infty)$ ↓ ดี
R^2	$1 - \frac{\text{RSS}}{\text{TSS}}$	สัดส่วน variance ที่อธิบายได้	$(-\infty, 1]$ ↑ ดี

ผลลัพธ์จาก California Housing

Metric	Train	Test
R^2	0.613	0.606
RMSE	0.726	0.727

Residual Analysis

Residual Plot ที่ดี vs. ไม่ดี

```
import matplotlib.pyplot as plt
residuals = y_test - y_pred

fig, axes = plt.subplots(1, 2, figsize=(12, 4))

# Residuals vs Fitted
axes[0].scatter(y_pred, residuals, alpha=0.3, s=10)
axes[0].axhline(0, color='red', linestyle='--')
axes[0].set(xlabel='Predicted', ylabel='Residuals', title='Residuals vs Fitted')
```

```
# Distribution of residuals
axes[1].hist(residuals, bins=50, edgecolor='white')
axes[1].set(xlabel='Residuals', title='Distribution of Residuals')

plt.tight_layout()
```

Residuals ที่ดี: กระจายสม่ำเสมอรอบศูนย์ — ไม่มีรูปแบบ (pattern)

06

แบบฝึกหัดและ Workshop

Exercise & Hands-on

แบบฝึกหัด 3.1 — Simple Linear Regression

โจทย์

ให้นักศึกษาสร้าง Simple Linear Regression โดยใช้ **เฉพาะ** `MedInc` เป็น feature เดียว เพื่อทำนาย `MedHouseVal`

1. Split data (80/20), ไม่ต้อง scale สำหรับ Simple LR
2. Fit `LinearRegression` และดูค่า `coef_` กับ `intercept_`
3. Plot scatter plot พร้อมเส้น regression และคำนวณ R^2 และ RMSE บน test set
4. เปรียบเทียบผลกับ Multiple LR — ต่างกันอย่างไร?

Dataset: `sklearn.datasets.fetch_california_housing()`

แบบฝึกหัด 3.2 — Regularization (ขั้นสูง)

โจทย์

เปรียบเทียบ Linear Regression กับ **Ridge** และ **Lasso** บน California Housing

1. Import `Ridge`, `Lasso` จาก `sklearn.linear_model`
2. ทดลอง `alpha ∈ {0.01, 0.1, 1, 10, 100}` ด้วย 5-fold CV
3. Plot กราฟ **coefficient path** เมื่อ `alpha` เปลี่ยน
4. เลือก `alpha` ที่ดีที่สุดและรายงาน R^2 / RMSE บน test set
5. สังเกต: feature ไหนที่ Lasso ตัดออก (coefficient = 0)?

Dataset: California Housing · **Library:** `sklearn`, `matplotlib`

07

สรุปและบทเรียนถัดไป

Summary & What's Next

สรุป Module 03

สิ่งที่เรียนรู้ใน Module นี้

- ✅ หลักการ Linear Regression และการประมาณค่าด้วย OLS
- ✅ สมมติฐาน LINE และวิธีตรวจสอบด้วย Diagnostic Plots
- ✅ Multiple Linear Regression และปัญหา Multicollinearity (VIF)
- ✅ การสร้างโมเดลด้วย scikit-learn บน California Housing Dataset
- ✅ ประเมินโมเดลด้วย R^2, MAE, RMSE และ Residual Analysis

Module ถัดไป

Module 04 — Logistic Regression & Classification

เมื่อ target เป็น categorical — Binary classification, Sigmoid function, Confusion Matrix

แหล่งอ้างอิงและอ่านเพิ่มเติม

อ่านเพิ่มเติม

- James et al. (2023). **Introduction to Statistical Learning with Python** — Ch. 3
- Géron (2022). **Hands-On Machine Learning with Scikit-Learn** — Ch. 4
- Montgomery et al. (2021). **Introduction to Linear Regression Analysis** — Ch. 2–3

แหล่งข้อมูลออนไลน์

- scikit-learn: LinearRegression
- Statquest: Linear Regression
- California Housing Dataset

คำถาม?

Questions & Discussion

ผศ.ดร. ทวีศักดิ์ สมานชื่น

taweesak.sam@mahidol.ac.th

คณะวิศวกรรมศาสตร์ · มหาวิทยาลัยมหิดล

สไลด์และ notebook: github.com/bdi-mahidol/BDAT501